



INSTITUTO SUPERIOR DE ENGENHARIA DE LISBOA (ISEL)

DEPARTAMENTO DE ENGENHARIA INFORMÁTICA (DEI)

MEIC & MEIM

MESTRADO EM ENGENHARIA INFORMÁTICA E COMPUTADORES

MESTRADO EM ENGENHARIA INFORMÁTICA E MULTIMÉDIA

APRENDIZAGEM E MINERAÇÃO DE DADOS

Projeto A

Grupo D09

Tiago Alcobia (50521)

Miguel Alcobia (50746)

Fábio Pestana (50756)

Docente

Professor Paulo Trigo

Outubro, 2025

Índice

Índice	i
1 Introdução	1
2 Contexto e Análise	2
3 Construção do <i>Dataset</i>	3
3.1 Formato 3-Row-Header (v1_dataset)	5
3.2 Formato Header-with-Attribute-Type (v2_dataset)	5
3.3 Dataset finalizado	5
4 Implementação da Classificação ddo Método 1R	7
4.1 Solução <i>Deployable</i>	7
5 Conclusões e Trabalho Futuro	9
Bibliografia	11

Capítulo 1

Introdução

Este projeto de laboratório tem como objetivo central explorar as relações fundamentais entre dados, informação e conhecimento e implementar as técnicas e algoritmos lecionados nas primeiras aulas da Unidade Curricular.

O projeto contemplará a implementação de diversas abordagens, desde técnicas estatísticas (como 1R e regra de Bayes) até à indução de árvores de decisão (J4.8/C4.5, ID3) e métodos baseados em instâncias (KNN com suporte KDTree). Paralelamente, desenvolveremos competências na análise, modelação e validação de projetos de mineração de dados, utilizando ferramentas específicas para gestão de dados (PostgreSQL), descoberta de conhecimento (Orange) e implementação de algoritmos (Python).

No âmbito do Cenário A, é assumido o centro médico "MedKnow" como sendo um cliente, que solicita o desenvolvimento de um protótipo de sistema para auxiliar atividades diárias da equipa de oftalmologia, bem como uma perspetiva estratégica através da identificação de padrões relevantes nos dados históricos de prescrição de lentes. Este cenário permitirá a aplicação prática dos conceitos e técnicas exploradas, demonstrando o valor da transformação de dados do trabalho diário em conhecimento clínico significativo.

Capítulo 2

Contexto e Análise

Foi fornecida uma amostra do dataset que se pretende criar.

Para começar, o grupo desenvolveu um rotina diária para a empresa da Medknow. Os pacientes desta empresa, são submetidos a diferentes e com o resultado de cada um chegam ao tipo de lente mais recomendado para a pessoa.

Esta prescrição é feita tendo em conta: a idade da pessoa, o tipo de prescrição, a presença de estigmatismo na pessoa ou não, taxa de lacrimejo e o tipo de lente recomendado para a pessoa.

Estes dados devem ser guardados numa base de dados onde cada paciente tem as suas prescrições, e informações que levaram a essa tomada de decisão.

Para facilitar as prescrições, a MedKnow quer automatizar este processo.

Em cada consulta são registados os dados do paciente (nome, idade), a sua condição ocular (por exemplo, miopia, hipermetropia, astigmatismo) e os resultados relevantes dos exames (por exemplo, taxa de produção de lágrimas, presença de astigmatismo, histórico de prescrição de óculos).

Capítulo 3

Construção do *Dataset*

Tendo por base o contexto apresentado anteriormente, fez-se a seguinte base de dados para servir de base para o *dataset* que será usado.

O esquema central assenta em seis entidades principais:

- **PATIENT** – possui a informação básica do paciente como o nome completo, um id, e data de nascimento que permite calcular a faixa etária (“young”, “pre-presbyopic”, “presbyopic”) de forma dinâmica.
- **DOCTOR** – contém o id e nome do médico responsável pelo exame ou prescrição.
- **DISEASE** – id da doença e nome da doença, com descrição opcional.
- **tear_rate** – entidade que padroniza os dois tipos possíveis de taxa de lacrimejo: “normal” ou “reduced”.
- **recommended_lens** – entidade que define os três tipos de lentes possíveis: “hard”, “soft” ou “none”.

Para representar os relacionamentos entre estas entidades durante o processo clínico, foram criadas duas tabelas:

- **patient_doctor_exam** – representa um exame, associando paciente, médico, data, tipo de exame e taxa de lacrimejo observada.
- **patient_doctor_disease** – representa a prescrição resultante, ligando o paciente, o médico, a doença diagnosticada, o exame correspondente e o tipo de lente recomendada.

Também se criou a tabela **prescription_diseases** para suportar casos em que uma prescrição possa estar associada a mais do que uma doença, como é o caso do paciente ter astigmatismo e outra doença.

Para facilitar a consulta dos dados foram criadas duas vistas:

- **v_exam** – agrupa toda a informação relevante dos exames.
- **v_prescription** – agrupa os dados da prescrição.




Figura 3.1: Modelo Entidade-Associação da Base de Dados

Para permitir a aplicação de algoritmos de data mining sobre os dados, foram desenvolvidas vistas (trabalhadas em laboratórios anteriores) que tornam os dados compatíveis com a ferramenta Orange. Estes formatos seguem duas abordagens distintas.

3.1 Formato 3-Row-Header (v1_dataset)

Esta vista é a que será usada para a continuidade do trabalho e organiza os dados no formato do Orange, composto por três linhas de cabeçalho:

- **Linha 1:** Nomes dos atributos (age, prescription, astigmatic, tear_rate, lenses)
- **Linha 2:** Tipos de dados (discreto para todos os atributos)
- **Linha 3:** Especificação da variável classe (lenses)

A construção desta vista baseia-se numa hierarquia de vistas auxiliares:

- **v_prescription_with_astigmatic** – vista intermédia que combina a doença principal (miopia ou hipermetropia) com a verificação de astigmatismo.
- **v1** – vista principal que seleciona e formata os atributos relevantes para o modelo preditivo
- **v1_domain**, **v1_attr_types**, **v1_class** – vistas que definem os metadados do cabeçalho que formam os *headers*

3.2 Formato Header-with-Attribute-Type (v2_dataset)

Esta vista utiliza uma formatação mais simplificada, onde os metadados são apresentados na primeira linha com o seguinte formato:

- **atributo#D** – para atributos discretos (age, prescription, astigmatic, tear_rate)
- **atributo#c** – para a variável classe (lenses)

3.3 Dataset finalizado

Com a vista v1 ficamos com os atributos apresentados na amostra fornecida:

- **age** – faixa etária do paciente (young, pre-presbyopic, presbyopic)

- **prescription** – condição ocular principal (myopia, hypermetropia)
- **astigmatic** – existência de astigmatismo (yes, no)
- **tear_rate** – taxa de lacremejo (normal, reduced)
- **lenses** – tipo de lente recomendada (hard, soft, none) que é a classe

A exportação dos dados é feito como lecionado em laboratórios anteriores usando o comando `COPY` do SQL para que o *dataset* seja exportado em CSV e no ficheiro a ser usado no Orange usou-se como delimitador o `\t` em vez da vírgula para que o Orange reconhecesse automática todos os campos do dataset.

Capítulo 4

Implementação da Classificação do Método 1R

O algoritmo 1R foi implementado em Python seguindo a abordagem apresentada nos slides da Unidade Curricular [Trigo, 2025]. A implementação baseia-se na implementação realizada para o laboratório 5 (`one_rule_metho_alg_v1`), com a diferença que foi necessário passar a estrutura do algoritmo para uma classe (`one_rule_method_alg_v2`):

Para além da construtor temos as seguintes funções:

- `_convert_to_orange_dataset()` - Converte arrays numpy (X, y) para um dataset Orange.
- `analyze_attribute()` - Analisa um atributo específico e gera as regras 1R.
- `fit()` - Treina o modelo.
- `predict()` - Faz as previsões, tendo por base o treino.
- `_print_results()` - Função para dar print aos resultados do melhor atributo que define a regra.

4.1 Solução *Deployable*

Para tornar a solução deployable criou-se os ficheiros `aux_split_eval.py` que tem funções que permitem todo o processo de análise, *split*, treino e *predict* e avaliação.

Também acrescentou-se os classificadores ID3 e Naive Bayes da biblioteca `sklearn` [Sklearn, 2025]. As funções de `split` foram baseadas nos slides da Unidade Curricular. As funções, além das diversas de *split* são:

- `orange_to_numpy()` - Converte um dataset Orange para arrays NumPy
- `get_class_name()` - Extrai nomes das classes do dataset
- `list_func_tt_split()` - Lista das funções de `split` e os respectivos argumentos.
- `list_func_classifier()` - Lista dos classificadores e os respectivos argumentos.
- `list_score_metric()` - Lista das funções das métricas score.

Por fim, temos a função `main()` que tem o seguinte funcionamento.

Começamos por carregar e extrair as *features* e a classe dos dados. Em seguida, existem três ciclos `for` dentro uns dos outros: o primeiro serve para percorrer as funções de *split* e obter os conjuntos de treino e teste. Em seguida, o segundo ciclo `for` percorre os classificadores e treina o modelo e faz o *predict* com os conjuntos obtidos anteriormente.

Por fim, após acabar de avaliar o *predict* com os resultados do ciclo anterior e os modelos treinados são guardados em ficheiros pickle e os seus metadados num ficheiro JSON.

Capítulo 5

Conclusões e Trabalho Futuro

Este cenário do projeto permitiu perceber melhor como funciona a criação de *datasets* desde da sua raiz e o funcionamento do algoritmo de classificação 1R.

O grupo chegou a fazer uma implementação do algoritmo de Naive Bayes (`naive_bayes_classifier_alg.py`), mas na versão *deployable* optou-se por usar o algoritmo do `sklearn` por uma questão de facilidade.

A maior dificuldade que o grupo enfrentou foi em encontrar um desenho eficaz da base de dados que daria origem ao *dataset* e a exportar os dados em CSV corretamente, pois quando o delimitador era uma vírgula o Orange não reconhecia os atributos e os valores automaticamente,

Outro fator que fez o grupo pensar foi o formato no qual guardariam o modelo depois deste ter sido treinado. Após alguma discussão entre os elementos do grupo, optou-se pelo Pickle, porque já era familiar por ter sido usado em Unidades Curriculares anteriores.

CHATS DE IA UTILIZADOS:

Os chats utilizados, foram-no para as seguintes ocasiões: Criar um ficheiro de treino, baseado num existente; transformar as funções criadas para o One Rule numa classe e saber como se passava um dataset do formato Orange para Numpy.

- <https://chat.deepseek.com/share/tj50bilgvaadr8v33l>
- <https://chat.deepseek.com/share/dbzbgnqnx5qq5knpo9>

- <https://chat.deepseek.com/share/tcjim84ett22xt80l9>

Bibliografia

[Sklearn, 2025] Sklearn (2025). Scikit-learn: Machine learning in python.
<https://scikit-learn.org/stable/>. Acedido: 2025.

[Trigo, 2025] Trigo, P. (2025). Slides de aprendizagem e mineração de dados.
Disponibilizado via Moodle. Acedido: 2025.