



INSTITUTO SUPERIOR DE ENGENHARIA DE LISBOA (ISEL)

DEPARTAMENTO DE ENGENHARIA INFORMÁTICA (DEI)

MEIM

MESTRADO EM ENGENHARIA INFORMÁTICA E MULTIMÉDIA
SISTEMAS GENERATIVOS E AGENTES INTELIGENTES MULTIMODAIS

Mini-Projecto 2 — RAG Pipeline

Miguel Alcobia (50746)

Fábio Pestana (50756)

Docente

Professor Arnaldo Abrantes

Maio, 2026

Índice

Índice	i
1 Introdução	1
2 O que é o RAG	2
3 Corpus e escolha	3
4 Pipeline e Decisões	5
4.1 Ingestão	5
4.2 Chunking	5
4.3 Embedding	6
4.4 Vector Store	7
4.5 Retrieval	8
4.6 Generation	8
5 Benchmark	10
6 Conclusão	19

Capítulo 1

Introdução

Este relatório demonstra o desenvolvimento do Mini-Projecto 2, que consistia num sistema RAG (Retrieval-Augmented Generation). O objetivo do projeto é construir um pipeline que, dada uma pergunta, identifique os documentos relevantes de um corpus específico e gere uma resposta fundamentada nesse conteúdo. Com esta abordagem, tenta-se evitar alucinações.

Dado que as aulas decorreram apenas até a 7.^a semana, o trabalho contempla apenas a implementação e adaptação do pipeline introduzido nessa semana (aula 07). Não foram implementados os conteúdos das semanas 8 e 9 (avaliação, estratégias avançadas de retrieval, reranking, hybrid search. etc.) na sua totalidade. Consequentemente, as comparações apresentadas incidem sobre as decisões que foi possível testar dentro do tempo disponível: duas estratégias de chunking (fixed-size vs sentence-aware, chunk-sizes diferentes), dois modelos de embedding (paraphrase-multilingual-MiniLM-L12-v2 vs nomic-embed-text), diferentes estratégias de retrieval (k=3, k=5, k=10), dois modelos de geração (llama3.2:3b vs qwen2.5:7b) e duas versões da prompt de sistema. Estas comparações são documentadas ao longo da secção de decisões de pipeline.

O corpus escolhido é composto por capítulos de um livro de fantasia escrito por um dos elementos do grupo. A escolha deve-se ao facto de obedecer aos critérios exigidos no guião: o conteúdo está fora dos pesos do LLM, é verificável pelos autores e excede as 20 páginas de texto equivalentes. Ao usar um corpus autoral, garante-se que o sistema RAG consulta de facto as fontes, visto que não conhece a história criada pelos alunos.

Capítulo 2

O que é o RAG

O RAG surge como uma resposta à sua tendência dos LLM para alucinar, ou seja, gerar conteúdo crível, mas factualmente incorreto. Esta limitação decorre do próprio objetivo de otimização dos LLMs, que privilegia a verossimilhança estatística em detrimento da verdade factual.

O RAG, em vez de confiar exclusivamente no conhecimento guardado nos pesos do modelo, pesquisa dinamicamente nos documentos quais são relevantes e usa esses documentos como contexto para a geração da resposta.

Capítulo 3

Corpus e escolha

Como referido na introdução, o corpus escolhido é composto por capítulos de um livro de fantasia escrito por um dos elementos do grupo. A escolha deve-se ao facto de obedecer aos critérios exigidos no guião: o conteúdo está fora dos pesos do LLM, é verificável pelos autores, e excede as 20 páginas de texto equivalentes. Ao usar um corpus autoral, garante-se que o sistema RAG consulta de facto as fontes, visto que não conhece a história criada pelos alunos.

Inicialmente, tínhamos, além do texto do capítulo, o seu resumo e uma lista das personagens presentes, mas ao realizar os testes chegou-se à conclusão que não era necessário e que, em alguns casos, até enviesava as respostas.

O formato inicialmente testado no corpus (versão final sem as Personagens e Resumo) era o seguinte:

```
# Parte I: ...
## Capítulo 1: ....

## Personagens presentes
- Personagem 1
- Personagem 2
- Personagem 3

## Resumo
(...)
```

```
## Texto completo
```

```
(...)
```

Prompt usado no começo do trabalho

Capítulo 4

Pipeline e Decisões

4.1 Ingestão

Leitura de todos os ficheiros com extensão `.md` da diretoria `corpus/`, extraíndo o conteúdo e o nome do ficheiro como metadado `source`.

```
# Parte I: ...  
## Capítulo 1: ....  
  
## Texto completo  
  
(...)
```

Acima está o formato de cada ficheiro do corpus usado no final do trabalho. Optou-se por utilizar ficheiros Markdown, seguindo o conselho do professor devido à sua simplicidade e à não necessidade de filtrar conteúdo como nos PDFs.

A função `load_corpus` carrega todos os ficheiros dessa diretoria em dicionários, nos quais temos o nome do ficheiro e o seu conteúdo. Isto é útil para descobrir os chunks que virão a ser usados.

4.2 Chunking

Foram implementadas duas estratégias de *chunking*:

1. **Fixed-size** (função `chunk_fixed_size`)
2. **Sentence-aware** (função `chunk_by_sentences`)

No **fixed-size**, variou-se o `chunk_size` entre 200 e 800 caracteres (com overlap de 50), tendo-se verificado que 800 introduzia ruído e 200 fragmentava demasiado o texto; o valor de 500 caracteres revelou o melhor equilíbrio. No **sentence-aware**, testou-se overlap de 1 e 2 frases (com `max_chunk_size=500`), concluindo-se que 2 frases geravam redundância desnecessária, enquanto 1 frase preservava o contexto de forma mais eficiente.

O método de chunking escolhido foi o baseado em frases, pois este mantém a integridade semântica, permitindo que o modelo responda melhor a perguntas. O método **fixed-size** também foi testado, no entanto, apresenta uma limitação estrutural importante: divide o texto estritamente por contagem de caracteres, ignorando fronteiras de frases ou parágrafos. Na prática, isto significa que uma frase pode ser cortada a meio. O modelo recebe cada chunk isoladamente e, mesmo com overlap, pode perder o contexto da frase.

Nos testes realizados, a estratégia **fixed-size** demonstrou resultados semelhantes ou piores em relação à estratégia baseada em frases, por este motivo escolheu-se a estratégia baseada em frases.

4.3 Embedding

Para a representação vetorial dos chunks, testaram-se três modelos: **paraphrase-multilingual-MiniLM-L12-v2** (via `sentence-transformers`), **nomic-embed-text** (via Ollama) e **all-MiniLM**. Dos três modelos escolheu-se o primeiro.

O **paraphrase-multilingual-MiniLM-L12-v2** é um modelo leve que produz embeddings de 384 dimensões e suporta mais de 50 línguas, incluindo português. Foi o que apresentou melhores resultados na recuperação de chunks relevantes e tempo de execução adequado. Nas perguntas de teste, recuperou consistentemente os chunks corretos para as perguntas fáceis e médias.

O **nomic-embed-text** (via Ollama) foi testado como alternativa local, seguindo a sugestão operacional da aula 07. No entanto, apresentou dois problemas: os chunks recuperados não continham a resposta, apesar desta existir no corpus e o tempo de execução era elevado.

O **all-minilm** foi testado mas não funcionou no projeto, pelo que foi excluído da comparação.

Neste passo, utilizou-se a biblioteca **sentence-transformers** para gerar embeddings, esta biblioteca trata de carregar modelos pré-treinados, gerenciar o tokenizer, utiliza a função **model.encode()** para passar uma lista de textos e processá-los em batches e realiza normalizações sobre os vetores para facilitar o cálculo de similaridade de cosseno.

Sem o **sentence-transformers**, seria necessário carregar o modelo e implementar todos os tópicos referidos anteriormente.

4.4 Vector Store

Para o armazenamento e recuperação dos embeddings, utilizou-se o ChromaDB na sua variante persistente (**PersistentClient**). Esta foi a mesma biblioteca utilizada na aula 07, optou-se por mantê-la devido a esta ter funcionado sem problemas durante o desenvolvimento do projeto.

O ChromaDB foi configurado com persistência em disco na diretória `./chroma_db`, onde organizou-se as coleções por estratégia de chunking:

- `corpus_mp2_fixed`: contém os chunks gerados pela estratégia `fixed-size`
- `corpus_mp2_sentences`: contém os chunks gerados pela estratégia das frases.

Esta separação permitiu testar e comparar as duas estratégias de chunking sem re-indexar os documentos de cada vez, poupando tempo de execução e garantindo consistência nas medições. A função `build_pipeline()` verifica se a coleção já existe, se existir e `recreate_collection=False`, reutiliza os embeddings já calculados.

Sem o ChromaDB, seria necessário implementar manualmente a comparação entre os chunks via similaridade de cossenos, implementar a persistência dos dados em disco e a filtragem dos metadados.

4.5 Retrieval

Para a fase de Retrieval testaram-se diferentes valores de **k** (número de chunks recuperados por query), sendo estes:

- $k = 3$: Revelou-se insuficiente. Em várias perguntas, os 3 chunks recuperados não continham toda a informação necessária, levando a respostas parciais ou incompletas.
- $k = 10$: Recuperava mais contexto que $k=3$, mas introduzia ruído, o que confundia o modelo, levando a este dar respostas incorretas.
- $k = 5$ (versão final): Apresentou o melhor equilíbrio, recupera contexto suficiente para as *queries* sem adicionar ruído.

4.6 Generation

Para a geração das respostas, testaram-se dois modelos locais via Ollama: **qwen2.5:7b** e **llama3.2:3b**. Optou-se pelo primeiro, que apresentou respostas mais consistentes e alucinou menos.

O qwen2.5:7b (7 mil milhões de parâmetros) demonstrou boa capacidade de seguir instruções em português e de sintetizar informação proveniente de múltiplos chunks. O llama3.2:3b (3 mil milhões de parâmetros) foi testado mas apresentou piores resultados: as respostas eram frequentemente mais vagas, ocasionalmente omitiam detalhes presentes no contexto e, em algumas perguntas, demonstrou menor capacidade de seguir as instruções de "responder apenas com base no contexto".

A *prompt* inicial estava em inglês, durante os testes observou-se que o modelo alucinava e respondia em inglês, optou-se por reescrever a prompt em português e indicar as regras através de uma numeração (*instruction prompting*). Esta alteração na prompt melhorou os resultados do modelo, onde reduziu casos de alucinação.

```
SYSTEM_PROMPT = """"És um assistente que responde APENAS  
com base no contexto.
```

REGRAS:

1. Lê TODO o contexto com atenção.
2. Se a resposta estiver no contexto, indica a resposta, mesmo que seja preciso juntar informação de múltiplos chunks. Sê conciso.
3. Se não estiver, diz: "Não tenho informação suficiente para responder."
4. Não inventes nem adiciones informação.

Contexto:

{context}

O sistema não cita fontes nas respostas geradas, no entanto as fontes são registadas, onde para cada query guarda-se num ficheiro txt, os 5 chunks recuperados com os respetivos metadados (nome do ficheiro e índice do chunk). O que permite verificar se os erros nas respostas devem-se ao retrieval ou à geração.

Capítulo 5

Benchmark

Perguntas Fáceis

Pergunta 1: Como se chama a técnica de esgrima que Madalys ensina?

Resposta esperada: Triângulo de Fogo

Chunks relevantes? Sim

Resposta (fixed): A técnica de esgrima que Madalys ensina chama-se Triângulo de Fogo.

Resposta (sentences): A técnica de esgrima que Madalys ensina chama-se Triângulo de Fogo.

Correcta? Sim

Fiel ao contexto? Sim

Pergunta 2: Quantos anos tem Bellya?

Resposta esperada: 153 anos

Chunks relevantes? Sim

Resposta (fixed): Bellya tem 153 anos.

Resposta (sentences): Bellya tinha 153 anos quando foi mencionada no contexto.

Correcta? Sim

Fiel ao contexto? Sim

Pergunta 3: O que é o Bloco de Gelo?

Resposta esperada: Solitária em Isidav, revestida de gelo, comida mínima, uma manta.

Chunks relevantes? Sim

Resposta (fixed): O Bloco de Gelo é uma solitária em Isidav revestida de gelo, onde os prisioneiros recebem apenas a comida mínima necessária para não morrer e são fornecidos apenas uma manta para se proteger do frio extremo.

Resposta (sentences): O Bloco de Gelo é um local na prisão de Isidav onde os presos podem ficar solitários. É todo revestido de gelo, a comida servida é mínima para evitar que os prisioneiros morram de fome e apenas uma manta é fornecida para proteger dos efeitos do gelo, o que os guardas consideram já um atendimento considerado dado a fama da prisão.

Correcta? Sim

Fiel ao contexto? Sim

Pergunta 4: Há quantos anos o filho de Singrek morreu?

Resposta esperada: 47 anos

Chunks relevantes? Sim

Resposta (fixed): O filho de Singrek morreu há quarenta e sete anos.

Resposta (sentences): O filho de Singrek morreu há quarenta e sete anos.

Correcta? Sim

Fiel ao contexto? Sim

Pergunta 5: O que acontece a Nelguz durante a tortura?

Resposta esperada: Nelguz sofre ferimentos nas costas, ombro direito afetado, punho envolto em tecido, e foi chicoteado no olho direito (faixa a cobrir o olho).

Chunks relevantes? Sim

Resposta (fixed): Nelguz sofreu uma lesão no ombro direito com feridas ligeiramente profundas e também teve o punho envolvido em tecido, provavelmente devido a alguma forma de amarrar ou retenção. Durante a tortura, ele foi chicoteado no olho direito pelo guarda Salok, resultando numa grande faixa a cobrir-lhe o olho ferido.

Resposta (sentences): Nelguz foi torturado por Vankom e Holont para obter informações sobre o esconderijo da Resistência.

Correcta? Não

Fiel ao contexto? Não

Notas: No caso do sentences, diz o caso que originou a tortura, mas não as

consequências que o personagem sofreu. No fixed ele alucina.

Pergunta 6: Qual é o nome da estalagem onde o grupo pernoita?

Resposta esperada: Rato Majestoso (nome real) – “Rato Asqueroso” é uma piada de Ardicep.

Chunks relevantes? Sim

Resposta (fixed): A estalagem onde o grupo pernoita chama-se Rato Asqueroso.

Resposta (sentences): A estalagem onde o grupo pernoita chama-se Rato Asqueroso.

Correcta? Não

Fiel ao contexto? Sim, mas interpretou o trocadilho como o nome verdadeiro

Pergunta 7: Qual é o nome do falcão de Keyla?

Resposta esperada: Okul

Chunks relevantes? Sim

Resposta (fixed): “O nome do falcão de Keyla é Okul.”

Resposta (sentences): “O nome do falcão de Keyla é Okul.”

Correcta? Sim

Fiel ao contexto? Sim

Pergunta 8: Qual é o símbolo da família Karkad?

Resposta esperada: Um leopardo-das-neves

Chunks relevantes? Sim

Resposta (fixed): O símbolo da família Karkad é um leopardo-das-neves.

Resposta (sentences): O símbolo da família Karkad é um leopardo-das-neves.

Correcta? Sim

Fiel ao contexto? Sim

Pergunta 9: O que significa ‘Ruf dellitra’ em anão?

Resposta esperada: “Para sempre”

Chunks relevantes? Sim

Resposta (fixed): ‘Ruf dellitra’ significa “Para sempre” em anão.

Resposta (sentences): ‘Ruf dellitra’ significa “Para sempre” em anão.

Correcta? Sim

Fiel ao contexto? Sim

Pergunta 10: O que Ardicep faz ao pai após Elprid cair?

Resposta esperada: Acerta na mão do pai com o chicote, fazendo-o largar o machado; chicoteia o pônei, fazendo o pai cair; recusa-se a olhar para trás.

Chunks relevantes? Sim

Resposta (fixed): Ardicep acertou no machado do pai com o chicote, fazendo-o largar imediatamente a ferramenta. Em seguida, chicoteou o pônei pertencente ao pai, causando que ele também caísse.

Resposta (sentences): Ardicep chicoteia o pônei, fazendo-o levantar as patas da frente e derrubar Bendrak. Em seguida, ele recusa-se a olhar para trás, não querendo verificar o estado do pai.

Correcta? Sim

Fiel ao contexto? Sim

As primeiras dez perguntas foram realmente fáceis para o modelo, que demonstrou uma boa capacidade de extração dos factos explícitos no contexto. Em 9/10 perguntas, o modelo respondeu corretamente tanto na versão (**fixed**) como na (**sentences**). A única exceção foi a Pergunta 5, em que o modelo alucinou na resposta (**fixed**) e forneceu uma resposta incompleta na (**sentences**). Na Pergunta 6, o modelo baralhou-se com um trocadilho interpretando o nome incorreto da estalagem como verdadeiro.

Perguntas Médias

Pergunta 11: Que tipos de sofrimento e privações Bellya enfrenta durante o seu cativeiro em Isidav?

Resposta esperada: Trabalho árduo (acartar sacos de entulho), magreza por fome, comida escassa, não dormiu uma semana devido aos gritos do Louco.

Chunks relevantes? Sim

Resposta (fixed): Bellya enfrenta vários tipos de sofrimento e privações durante o seu cativeiro em Isidav. Ela está magra, indicando que tem passado por períodos de fome ou escassez de alimentos. Além disso, foi incumbida de uma tarefa árdua de acartar sacos de entulho, que se tornou extraordinariamente difícil para ela dada a sua condição atual. A comida é escassa e a falta dela contribui para o seu estado físico debilitado. Adicionalmente, não dormiu durante toda uma semana devido ao Louco, um prisioneiro que fazia gritos noturnos sem parar.

Resposta (sentences): Não tenho informação suficiente para responder.

Correcta? Sim (fixed)

Fiel ao contexto? Sim (fixed)

Notas: No fixed, o modelo acerta, no sentences ele não consegue responder.

Pergunta 12: Que eventos levam à morte de Elprid no final da história?

Resposta esperada: Elprid morre ao cair no rio após ser atingido/derrubado por Bendrak (pai de Ardicep) durante a fuga; não é por enforcamento (isso é no início, como flashback?).

Chunks relevantes? Parcial (os chunks mostram que o pai de Ardicep o matou, mas não detalham o evento exato)

Resposta (fixed): A morte de Elprid ocorre como resultado de uma execução por enforcamento ordenada pelo Rei Moglum Clandolf, pois Elprid e Ardicep Karkad foram acusados de serem líderes de um grupo que conspirava contra o líder.

Resposta (sentences): A morte de Elprid foi causada por seu próprio pai. Ardicep menciona que “O meu pai matou-o”, indicando que Elprid foi assassinado pelo seu próprio pai durante a execução.

Correcta? Não

Fiel ao contexto? Não

Notas: No fixed, o modelo confundiu a cena inicial da forca com a morte real e o sentences está parcialmente correto, pois a relação entre os personagens está errada, mas o evento está correto.

Pergunta 13: Qual a relação entre Singrek, a morte dos pais de Keyla e a formação da Resistência?

Resposta esperada: Singrek, quando ainda era general em Dryard, matou os pais de Keyla. Esse evento pode ter motivado Keyla a juntar-se à Resistência, e Singrek quer redimir-se.

Chunks relevantes? Sim

Resposta (fixed): Não tenho informação suficiente para responder.

Resposta (sentences): Singrek matou os pais de Keyla quando ainda era general em Dryard. Esta informação foi crucial para Keyla decidir permanecer na Resistência, juntando-se a Elprid e Vetalis. A morte dos pais de Keyla parece ser um dos principais motivos que a levaram a se envolver na resistência contra aqueles que ela considera responsáveis.

Correcta? Sim (sentences)

Fiel ao contexto? Sim (sentences)

Pergunta 14: Que lesões permanentes ou graves sofrem Bellya, Nelguz, Salok, Vetalis e Elprid?

Resposta esperada: Nelguz: feridas no ombro, punho envolto, olho ferido; Salok: olho ferido; Bellya: magreza, ossos salientes (não permanente); Vetalis: costas abertas por chicotadas; Elprid: morre.

Chunks relevantes? Sim

Resposta (fixed): Nelguz sofreu uma ferida no olho pelos chicotadas dos guardas. Salok teve um olho ferido pelo chicote. Vetalis não sofreu lesões permanentes mencionadas, mas estava chocado com o estado de Bellya. Não há menção a lesões permanentes ou graves para Bellya, Elprid ou Heican no contexto fornecido.

Resposta (sentences): Nelguz tem ferimentos nas costas e um ombro afetado por feridas ligeiramente profundas. Bellya tem uma cicatriz na bochecha. Não há menção a lesões permanentes ou graves para Salok, Vetalis ou Elprid no contexto fornecido.

Correcta? Parcial

Fiel ao contexto? Parcial

Notas: No sentences, apenas acerta o personagem Nelguz e no fixed, acerta sobre a personagem Salok. Nos restantes alucina.

Neste grupo, a complexidade aumentou e exigiu síntese de múltiplos factos ou compreensão de eventos mais complexos. O modelo apresentou comportamento irregular: na Pergunta 11, acertou apenas no (**fixed**); na Pergunta 12, errou em ambas as versões, confundindo eventos narrativos; na Pergunta 13, acertou apenas no (**sentences**); e na Pergunta 14, obteve apenas acertos parciais, com alucinações pontuais. Observou-se uma tendência para o modelo inventar informação quando a resposta exigia uma análise mais elaborada. Quando optava por “*Não tenho informação suficiente*”, tendia a acertar.

Perguntas Armadilha

Pergunta 15: Onde fica localizada a cidade de Alovuén?

Resposta esperada: Alovuén é mencionada como onde fica o Conselho Mágico; localização exata não está nos chunks.

Chunks relevantes? Não

Resposta (fixed): Não tenho informação suficiente para responder.

Resposta (sentences): Não tenho informação suficiente para responder.

Correcta? Sim

Fiel ao contexto? Sim

Notas: Resposta honesta, pois não há informação sobre a pergunta.

Pergunta 16: Como se chama a esposa de Singrek?

Resposta esperada: Mapullya (é a esposa de Vetalis, não de Singrek – atenção!)

Chunks relevantes? Parcial (os chunks mostram que a mulher de Singrek abandonou-o, mas nunca dão o nome dela)

Resposta (fixed): A esposa de Singrek é Mapullya.

Resposta (sentences): Não tenho informação suficiente para responder.

Correcta? Sim (sentences)

Fiel ao contexto? Sim (sentences)

Notas: Resposta honesta (sentences), alucina no fixed, pois Mapullya é esposa de outro personagem.

Pergunta 17: Que relação familiar existe entre Gardiast e Vetalis?

Resposta esperada: Nenhuma relação familiar mencionada nos chunks. Gardiast é um mago que pediu a Vetalis para resgatar Elprid e Ardicep.

Chunks relevantes? Não

Resposta (fixed): Não tenho informação suficiente para responder.

Resposta (sentences): Não tenho informação suficiente para responder.

Correcta? Sim

Fiel ao contexto? Sim

Notas: Resposta honesta, pois não há informação sobre a pergunta.

Pergunta 18: Onde nasceu Elprid Slival?

Resposta esperada: Não mencionado nos chunks.

Chunks relevantes? Não

Resposta (fixed): Não tenho informação suficiente para responder.

Resposta (sentences): Não tenho informação suficiente para responder.

Correcta? Sim

Fiel ao contexto? Sim

Notas: Resposta honesta, pois não há informação sobre a pergunta.

Este conjunto foi desenhado para testar a honestidade do modelo perante a ausência de informação. O resultado foi maioritariamente positivo: nas Perguntas 15, 17 e 18, o modelo respondeu corretamente “*Não tenho informação suficiente*” em ambas as versões, demonstrando bom controlo de alucinações. A exceção foi a Pergunta 16, onde o modelo (**fixed**) alucinou ao atribuir incorretamente o nome Mapullya como esposa de Singrek (quando, na verdade, é esposa de Vetalis). Este caso ilustra que, mesmo quando o contexto *não* contém a resposta, o modelo por vezes tenta preencher a lacuna com informação parcialmente relacionada.

Capítulo 6

Conclusão

Apesar do pipeline RAG desenvolvido apresentar um desempenho satisfatório na maioria das queries fáceis e médias, ocorreram algumas falhas recorrentes.

Em diversas ocasiões, especialmente em perguntas médias que exigiam síntese de múltiplos chunks, o modelo recuperava corretamente os fragmentos relevantes, mas a resposta gerada pelo LLM era incompleta ou simplesmente "Não tenho informação suficiente para responder". Aqui o retrieval funcionou corretamente e a falha ocorreu na geração.

O modelo também revelou dificuldades com figuras de estilo, como trocadilhos e referências indiretas. Por exemplo, quando uma personagem era referida por uma alcunha ou apelido em vez do nome próprio, o modelo frequentemente não estabelecia a correlação, respondendo de forma incorreta ou parcial. Da mesma forma, relações entre personagens descritas de forma implícita não eram corretamente interpretadas. Este problema tem origem nos dois pontos, pois o retrieval recupera os chunks que contêm a alcunha, mas o embedding da query, que usa o nome próprio, pode não se alinhar perfeitamente com chunks que usam apenas a alcunha.

A falha mais interessante foi a query em relação às feridas dos personagens (pergunta 14), onde ele acerta as feridas de uma personagem e erra todas as restantes.

Com tempo adicional, adicionaríamos o conteúdo da aula 8 para melhorar o retrieval.